



דו"ח פרויקט בקורס מבוא לבינה מלאכותית

פתרון משחק Tower Defense בעזרת אלגוריתם גנטי



תוכן עניינים:

1. [הגדרת הבעיה](#)
2. [פתרון הבעיה](#)
 - 2.1 [הגדרת המתודולוגיה- אלגוריתם גנטי](#)
 - 2.2 [הגדרת הפתרון](#)
 - 2.3 [שימוש במתודולוגיה הגנטית למציאת הפתרון](#)
 - 2.4 [ויזואליזציה של פתרון](#)
3. [דיון מקדים על פרמטרי האלגוריתם הגנטי](#)
4. [תוצאות](#)
 - 4.1 [פתרון לדוגמא](#)
 - 4.2 [השפעת גודל האוכלוסייה](#)
 - 4.3 [השפעת אחוז המוטציה](#)
5. [מסקנות](#)
6. [נספחים](#)
 - 6.1 [קשיים בפתרון הבעיה](#)



1. הגדרת הבעיה



אנחנו רוצים לייצר סוכן שינצח במשחק ה-Tower Defense
https://en.wikipedia.org/wiki/Tower_defense

המשחק מתנהל על לוח משבצות שבו עוברת דרך אותה מנסים אויבים לחצות, מן הצד השמאלי של הלוח אל הימני. לפיכך, כל משבצת בלוח שאינה חלק מהדרך הזו היא משבצת משחק לגיטימית. כלומר, ניתן להציב בה מגדלים שונים שמגנים מפני האויבים ומנסים לחסל אותם.

במהלך המשחק מנסים גלים של אויבים, מרווחים זה מזה בהפסקות קצרות, לחצות את הלוח. האויבים מתחזקים במהלך המשחק ולכן יש להמשיך ולשפר את הצבת המגדלים ואת איכויותיהם.

בכל רגע נתון במשחק ניתן לבצע אחת מהפעולות הבאות:

1. קניית מגדל ומיקומו במשבצת משחק חוקית - ישנן 5 סוגי מגדלים שונים. לכל מגדל יש יכולות שונות (קצב ירייה, סוג ירייה, טווח ועוד) ועלות שונה.
2. מכירת מגדל - מזכה את הסוכן ב-70% מעלות המגדל ההתחלתי.
3. שדרוג מגדל קיים - ישנן 3 רמות של מגדל, הנבדלות זו מזו ביכולות של המגדל. עדכון מגדל עולה כסף.

Rapidfire Tower		\$ 50 6 2	\$ 80 12 2.5	\$ 250 25 3
Range Tower		\$ 50 15 0.8	\$ 100 18 1	\$ 250 25 1.3
Plasma Tower		\$ 50 5 0.3	\$ 100 10 0.5	\$ 250 15 0.7
Poison Tower		\$ 80 2 0.5	\$ 100 5 0.5	\$ 250 8 0.8
Slow Tower		\$ 80 2 0.5	\$ 100 5 0.6	\$ 250 8 1
\$ Price Damage per hit Firerate				

המשחק מתנהל תחת אילוץ כספי כאשר הצבת מגדלים או שדרוג מגדלים קיימים עולה כסף, והריגת אויבים ומכירת מגדלים מזכה בכסף.

כל אויב שמצליח לחצות את הלוח עולה לשחקן ב"חיים", וכאשר נגמרים החיים המשחק נגמר.

בחרנו למצוא פתרון לבעיה, סוכן אופטימלי למשחק, על ידי שימוש באלגוריתם גנטי.

2. פתרון הבעיה

2.1. הגדרת המתודולוגיה- אלגוריתם גנטי

רקע:

אלגוריתם זה משתמש במטאפורה של גנטיקה בשביל למצוא פתרון לבעיה, ונכונותו נסמכת על העיקרון האבולוציוני שלפיו "החזק שורד".

בהתאם למטאפורה, מטרת הפרט היא לשרוד. המטען הגנטי שאיתו הוא נולד הוא הקובע את התכונות והיכולות שיהיו לאינדיבידואל, ולכן הוא זה שיענה על השאלה האם הפרט ישיג את מטרתו לשרוד (ולהעביר את המטען הגנטי שלו לדורות הבאים) או לא (ולכן אט אט תעלם התכונה מהאוכלוסייה). תהליך זה של שינוי המטען הגנטי של האוכלוסייה לאורך הדורות קרוי אבולוציה. האבולוציה מתאפשרת באמצעות זיווג בין פרטים באוכלוסייה והופעה של מוטציות בגנומים של הפרטים החדשים שנוצרו. תהליכים אלו מאפשרים שונות באוכלוסייה שמולידה אוכלוסייה רב-גונית, עשירה ובעלת שרידות גבוהה. נציין את העובדה שבעיתות מצוקה קצב שינוי האוכלוסייה מואץ כתגובה לשינויים קיצוניים בסביבה על מנת לשמר את המין.

נציג כעת את הטרמינולוגיה הדרושה לנו לשם קריאת הדו"ח:

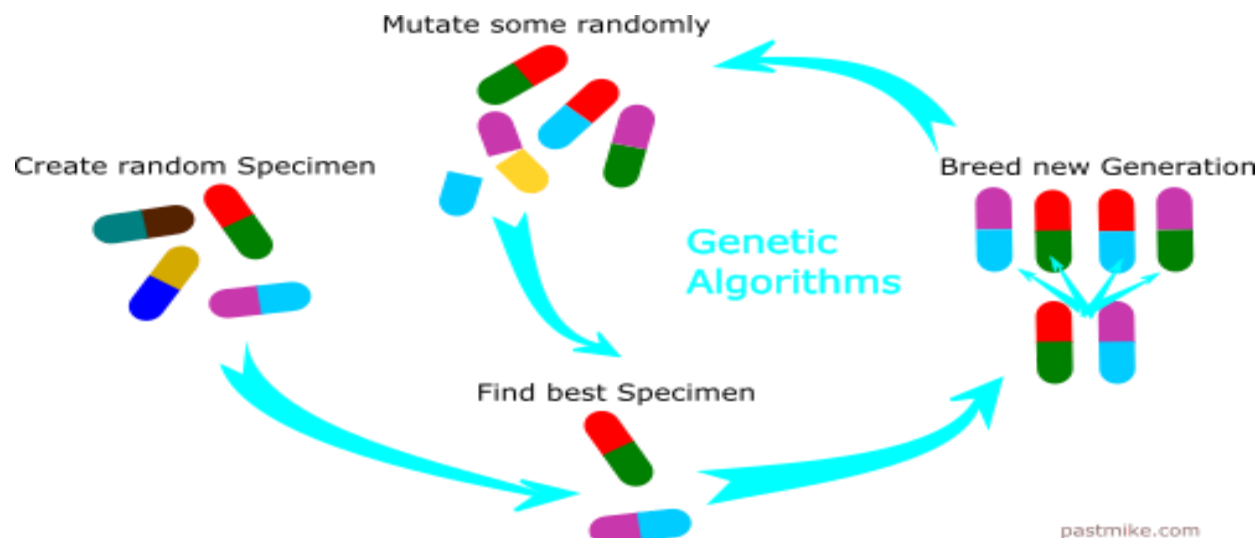
הגנום הוא ייצוג לפתרון הבעיה אותה נרצה לפתור באמצעות האלגוריתם. **אוכלוסייה** היא אוסף של **אינדיבידואלים**, כל אחד מהם מוגדר על ידי **גנום (פתרון)**. **דור** הוא אוכלוסייה ספציפית סדורה כרונולוגית. בין דורות יש התפתחות אבולוציונית שמתבצעת ע"י זיווג של האינדיבידואלים הטובים ביותר מהדור הקודם, וביצוע מוטציות רנדומליות על הצאצאים.

האלגוריתם פועל באופן הבא:

1. אתחול: בדור הראשון נאתחל אוכלוסייה ראשונית של אינדיבידואלים באופן רנדומלי.
2. לולאה: עד אשר יתקיים תנאי עצירה נבחר (מספר דורות מקסימלי, אחוז שיפור מדור לדור...)
נבצע:

- a. חישוב כשירות: מחשבים לכל אינדיבידואל באוכלוסייה את **רמת הכשירות** שלו באמצעות **פונקציית fitness**.
- b. סלקציה: בוחרים את האינדיבידואלים **הכשירים** ביותר מבין האוכלוסייה.
- c. Crossover: **מזווגים** בין האינדיבידואלים בקבוצת הכשירים ביותר אוכלוסייה חדשה המורכבת מאוסף צאצאים חוקי.
- d. Mutation: מבצעים **מוטציה** (חוקית) על הגנום של הצאצא החוקיים.

בכך אנחנו יוצרים בכל דור אוכלוסייה חדשה שמטענה הגנטי מגיע מהאינדיבידואלים הכשירים ביותר של הדור הקודם. כך מובטח לנו שהגנום לאינדיבידואל המוצלח ביותר מהדור האחרון יהיה זה המיטב, ולכן נקח אותו להיות הפתרון שלנו.




האלגוריתם הגנטי נסמך על מספר מטה-פרמטרים אשר חשיבותם והיחסים ביניהם משתנים בהתאם לבעיה אותה נרצה לפתור:


1. **גודל האוכלוסייה:** כמות האינדיבידואלים בכל דור.
2. **קצב המוטציות:** קצב המוטציות מבטא את מספר מוטציות שנצפה לראות בכל דור ודור.
3. **כמות האבות המייסדים לכל דור:** כמה אינדיבידואלים מהדור הקודם ניקח כדי לייצר מהמטען הגנטי שלהם את הדור החדש.
4. **מספר הדורות:** כמה דורות האלגוריתם יעבור עד שיגיע לפתרון (צורה אחת של קריטריון התכנסות לאלגוריתם).
5. **קצב התכנסות הדורות:** קריטריון התכנסות לאלגוריתם.
6. **הגנום:**
 - a. גודל: מספר הגנים שמרכיבים את הגנום של אינדיבידואל.
 - b. גנים: מהם הערכים שכל גן יכול לקבל.
7. **צורת הזיווג (crossover):** הצורה בה מייצרים גנום חדש משני גינומים.
8. **פונקציית ה-Fitness:** הפונקציה המשמשת לאומדן האינדיבידואל, פונקציית הכשירות.

נשים לב שהגנום מגדיר את מרחב החיפוש של הבעיה, והוא ייחודי לכל בעיה.

One Point Crossover



Multi Point Crossover



Uniform Crossover



2.2. הגדרת הפתרון

- ראשית נבחין שמהלך המשחק הוא רציף- בכל רגע במשחק ניתן לבצע את אחת מבין הפעולות החוקיות: קנייה, מכירה או שדרוג של מגדל, תחת האילוץ התקציבי.

כדי להתמודד עם כך, בחרנו להפוך את המשחק לדיסקרטי על ידי חלוקה של ציר הזמן למקטעים, ולאפשר ביצוע רצף פעולות חוקי רק בנקודות החלוקה.

בשלב זה היינו רוצים ללמוד מהו רצף הפעולות החוקי האופטימלי בין כל מקטע: **תגובות של הסוכן**.

- למידה גנטית של **תגובות של הסוכן** מצריכה לבטא גנום מעריכי בגודל הלוח: ההחלטה לבצע כל פעולה על כל תא בלוח. בשלב זה שקלנו לבצע את הלמידה בעזרת רשת נוירונים שמקבלת נתונים על העולם ומחליטה כיצד לנהוג.

בשל מימד הבעיה (והרצון לעסוק באלגוריתם גנטי קלאסי ולא בלמידה על ידי רשת נוירונים) בחרנו לנקוט גישה אחרת ולבטא גנום **כתצורה של לוח** (לצמצם את הבעיה להצבה חוקית של מגדלים מסוגים שונים בלוח).

בשלב זה היינו רוצים ללמוד מהי **התצורה החוקית אופטימלית** לכל מקטע (שעומדת באילוצים), ולהבין איך לקשור בין התצורות הללו כדי להגדיר פתרון לכל המשחק.

- כדי להשיג פתרון **חוקי** למשחק, שמורכב מרצף התצורות האופטימליות לכל מקטע, נצטרך להבטיח שכל תצורה מסוגלת להתקבל מהתצורה הקודמת לה על ידי רצף חוקי של פעולות שעומד באילוצים של התצורה הקודמת, הן באילוצי ההצבה והן באילוצים הכספיים.

כדי להבטיח זאת בחרנו לאפשר קיום של תצורת לוח רק אם היא עומדת מלכתחילה באילוצים הללו כלומר תצורת לוח (גנום של אינדיבידואל) לא חוקית תיפסל מלכתחילה.

שילוב הגישות הללו איפשר לנו להגדיר פתרון כרשימה של תצורות לוח (כאשר כל תצורה מתאימה לשלב דיסקרטי במשחק) וכאשר **המעבר** בין התצורות נעשה על ידי רצף פעולות חוקי שעומד באילוצי התקציבי של התצורה הקודמת.

2.3 שימוש במתודולוגיה הגנטית למציאת הפתרון

לפי הגדרת הפתרון שלעיל, החלטנו להשתמש בלמידה גנטית ברמת המקטע- נמצא פתרון אופטימלי לכל מקטע בעזרת למידה גנטית.


כמו כן האוכלוסייה הראשונית בכל מקטע תוקם מקבוצת הכשירים ביותר של המקטע הקודם. נבחין שעל ידי כך יתקיים לנו שכל פתרון למקטע מסוים ניתן לקישור אחורה לפתרון מהאוכלוסייה הראשונית ע"י רצף חוקי של פעולות שעומד באילוצים, כלומר תכונה זו מאפשרת לנו למצוא פתרון למשחק כולו.

בנוסף נציין שבכל דור ראשון של המקטעים (מלבד הראשון) לקחנו את האינדיבידואלים החזקים ביותר מהמקטע הקודם והגרלנו מספר מוטציות גדול פי 5 מדרך כלל משתי סיבות:

1. כיוון שאנחנו מתחילים מאוכלוסייה ספציפית, יש הטיה ברורה לקבוצת פתרונות מסויימת, צורת עבודה זו הכרחית עבור חוקיות הפתרון שלנו והכנסת מוטציות מרובות לפני תחילת הלמידה של המקטע מאפשרת לנו להכניס גיוון גנטי ורנדומליות שקיימת בריצה הקלאסית של האלגוריתם.
2. כיוון שהאויבים מתחזקים ממקטע למקטע הלחץ מהסביבה אל הסוכן שלנו גובר, קצב מוטציות מוגבר בנקודת זמן זו מאפשרת לסוכן להתגבר על לחץ זה.


לסיכום, תהליך הלמידה של הסוכן הגנטי שלנו מחולק למקטעים (מספר קבוע של שלבים במשחק). על כל מקטע תתבצע למידה לפי אופן הפעולה של האלגוריתם הגנטי שתיארנו לעיל. כל דור ראשון עבור מקטע מסויים יתבסס על האינדיבידואלים הכשירים ביותר מהדור האחרון של המקטע הקודם (מלבד המקטע הראשון בו נאתחל אוכלוסייה ראשונית רנדומלית). פתרון למשחק כולו יהיה סדרה של תצורות לוח (גנומים) מנצחות למקטעים במשחק, בעלות מעברים חוקיים ביניהן (עומדים באילוצי התקציבי).

The Solver:



2.4. ויזואליזציה של פתרון

פתרון למקטע מסוים במשחק הוא הצבה של מגדלים במשבצות על הלוח המיוצגת ע"י מערך של ערכים אותם אנו מתאימים למשבצת בלוח, כפי שניתן לראות למטה:



3. דיון מקדים על פרמטרי האלגוריתם הגנטי

כפי שהצגנו קודם, מטה-הפרמטרים של אלגוריתם למידה גנטית הם: גודל האוכלוסייה, קצב המוטציות, כמות האבות המייסדים לכל דור, מספר הדורות, קצב התכנסות הדורות, הגנום. נדון כעת במשמעותם בתהליך הלמידה:

- **גודל האוכלוסייה** - מקובל לחשוב כי ככל שהאוכלוסייה גדולה יותר, כך העושר הגנטי רב יותר ויאפשר לנו להימנע ממקסימום מקומי, וכי אוכלוסייה קטנה מדי יכולה להתכנס בטרם עת לפתרון. כמו כן, אוכלוסייה גדולה יותר מאפשרת לבטא יותר שונות בכל דור ולכן נוכל לצפות בפתרון המיטבי בדורות צעירים יותר של האוכלוסייה, אך ההתכנסות עלולה להיות איטית כשלעצמה.
- **קצב המוטציות** - ההנחה היא שככל שקצב המוטציות יהיה גדול יותר, ההתכנסות תהיה תזזיתית יותר, אבל כך נוכל להימנע ממקסימום מקומי. מנגד, קצב מוטציות קטן יותר יוביל להתכנסות חלקה יותר לפתרון אופטימלי.
- **כמות האבות המייסדים לכל דור** - עושר המטען הגנטי בדור הבא יהיה גדול יותר כאשר יהיו יותר אבות מייסדים, אך כמות גדולה מדי יכולה להאט את קצב ההתכנסות.
- **מספר הדורות** - ככל שנריץ יותר דורות כך נהיה יותר בטוחים כי הפתרון אליו הגענו הוא אכן האופטימלי, אך זה יגדיל משמעותית את זמן הריצה.
- **הגנום** - מגדיר את מרחב חיפוש הפתרונות שלנו. בבעיה שלנו, גודלו 209 ולכל גן 16 ערכים אפשריים. כלומר גודל מרחב החיפוש הוא 16^{209} .
- **צורת הזיווג** - ישנן דרכים שונות כיצד להחליט עבור כל גן אצל הצאצא האם ניקח את הגן של האם או של האב. כאשר ייתכן כי צורת זיווג מסוימת תוכל תחת תנאים מסוימים להגביל את הגיוון בצאצאים הנוצרים.
- **פונקציית Fitness**: מגדיר עד כמה אינדיבידואל כלשהו כשיר. במקרה שלנו, אינדיבידואלים שלא שרדו את המקטע קיבלו כשירות אפסית, אינדיבידואלים ששרדו אך איבדו חיים במהלך המקטע קיבלו ערכים בהתאם לחיים שאיבדו והכסף שהרוויחו, ואינדיבידואלים ששרדו ללא כל אובדן חיים קיבלו את הניקוד הגבוה ביותר בנוסף לבונוס על החסכנות שלהם בכסף במהלך והכסף שהרוויחו. המטרה הייתה לעשות הפרדה ברורה בין אינדיבידואלים ששרדו ללא כל פסילה את המקטע כיוון שהמטרה העיקרית של המשחק היא לשרוד.

היחסים בין הפרמטרים השונים:

- ראשית, **הגנום** מגדיר לנו את גודל מרחב החיפוש, ולכן את הערך של שאר הפרמטרים ננסה להסיק ממנו. בעבודתנו צמצמנו את לוח המשחק להיות חלק מהלוח המקורי כדי להקטין את מרחב החיפוש מפאת קוצר בזמני הלמידה.
- **גודל האוכלוסייה וקצב המוטציות** שניהם משפיעים על מגוון הפתרונות, אך קשה היה לנו להסיק מערך של אחד מהם על השני.
- בבחירת ערך קצב המוטציות הערכנו שנרצה ממוצע של בין 1 ל 3 מוטציות מדור לדור ולכן הקצב הושפע ישירות מגודל הגנום. כמו כן, בדור הראשון בכל מקטע הגדלנו את קצב המוטציות באופן משמעותי כדי לגשר על הקושי שבמעבר בין הסגמנטים השונים.
- ישנם שני פרמטרים שסברנו שמושפעים מגודל האוכלוסייה, והם **מספר הדורות וכמות האבות המייסדים**:

- אנו גורסים כי מספר דורות גבוה יותר יסייע לנו לאזן גודל אוכלוסייה קטן יותר כאשר אנו מסתמכים על המוטציות מדור לדור לייצר מגוון בפתרונות.
- כמות גדולה ככל האפשר של אבות מייסדים אמנם תאפשר לנו לשמור על מגוון פתרונות, אך בחירת גודל זה תלויה בגודל האוכלוסייה, כיוון שנרצה לזקק רק את האחוז המסוים הנבחר של אינדיבידואלים מוצלחים באמת מכל דור.
- בתחילה התלבטנו באיזה צורת זיווג להשתמש uniform crossover, single point crossover או multi-point crossover. לבסוף החלטנו כי כיוון שאנו מריצים כמות לא מבטלת של דורות, וכתלות בגודל הגיון, השימוש ב - single point crossover יגוון את הדור החדש באופן מספק.

לפיכך, הפרמטרים אותם בחרנו לבדוק בעבודתנו הם: גודל האוכלוסייה וקצב המוטציה, כיוון שלהערכתנו הם המשפיעים ביותר על הצלחת הסוכן הגנטי ללמוד פתרון לבעיה.

יש לציין כי הגדלים לאוכלוסיות בריצות שלנו נבחרו בהתאם למשאבים העומדים לרשותנו הן בזמן, הן בתוכנה אותה ניסינו לפתור והן בחומרה עליה נריץ. בפרט המימוש למשחק העומד בפנינו נכתב באופן כזה שהרצת יותר מכמות מסוימת של פתרונות ברצף, לשם למידה או בדיקה, בעייתית.

לכן ערכי הפרמטרים אותם בחרנו לבחון הינם:

- **גודל האוכלוסייה:** 20, 50, 100.
 - **קצב המוטציה:** 0.005, 0.01, 0.015.
- (יש לציין שחלק גדול מהמוטציות לא מתבצעות בשל האילוצים הכספיים של המשחק).

4. תוצאות

4.1. פתרון לדוגמא



פתרון לדוגמא שהוסק מהרצת האלגוריתם עם אוכלוסייה בגודל 100 וקצב מוטציה 0.01. בכל תמונה ברצף ניתן לראות את ההצבה שהסוכן למד בכל אחד מבין חמשת מקטעי המשחק.

ניתן לראות כי בין כל שתי הצבות סמוכות של הפתרון לפנינו ישנם הבדלים קטנים: שדרוג, הוספה, מכירה של מגדל במשבצת מסוימת. החוקיות של הפתרון מבטיחה כי כל מעבר בין שתי הצבות כאלה בנקודת הזמן בין המקטעים ישיגה ע"י מספר פעולות שהתקציב של הסוכן עומד בהן.

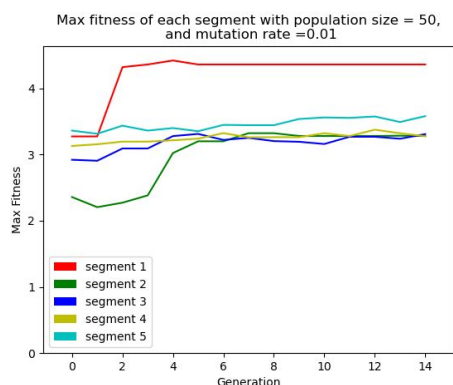
בנוסף, נשים לב כי כיוון שפונקציית הכשירות שלנו מתעדפת סוכנים חסכנים, השינויים בין ההצבות הן המינימליות שמאפשרות לסוכן לשרוד את המקטע, רובם ברמה 1 הזולה ביותר, ואין אף מגדל המוצב במקום ממנו אין הוא יכול לירות באויבים.

מבחינת סוג המגדלים שנבחרו ע"י הסוכן במקרה הזה אנו רואים כי רוב המגדלים הם מאותו הסוג, ובנוסף המגדלים הירוקים בצורת צלב הם המגדלים בעלי הטווח הגדול ביותר, אנו רואים שרובם מוצבים קרוב לפיתול כך שבמקום זה הטווח הגדול שלהם מקנה גישה לחלק הכי גדול באופן יחסי מהמסלול.

בחלקו הישר של הלוח (תחילתו) הסוכן הציב מגדלים עגולים, שהנזק שלהם הוא איזורי, כלומר משפיע על כמה אויבים. ז"א אומרת שבשלב הקשה ביותר (שלב הבוס) בו ישנם הרבה אויבים קטנים שמטרתם להסיט אש מהאויב הבוס, המגדלים העגולים יחסלו את האויבים הקטנים לפני שהם יגיעו לטווח של המגדלים הירוקים, וכך כל האש שלהם תתמקד בבוס.

מכאן ניתן לראות כי הסוכן אכן מצא אסטרטגיה אופטימלית למשחק.

4.2

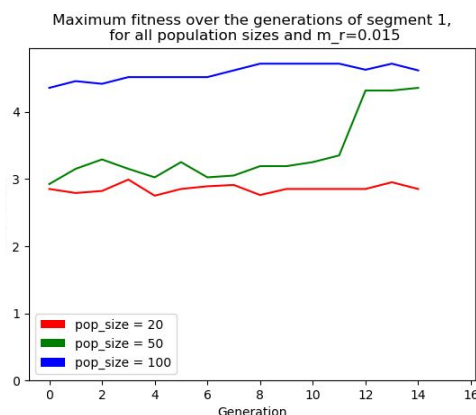
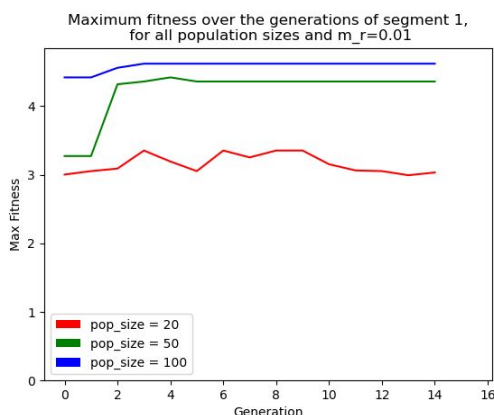
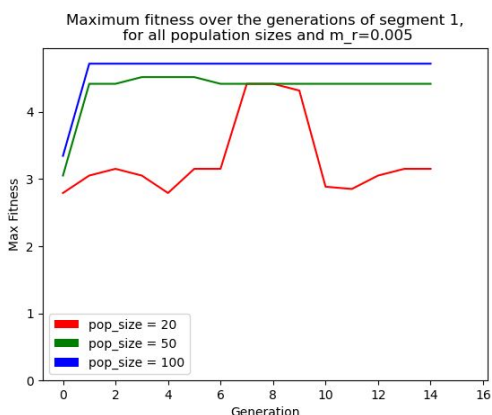


היכן שאנחנו מתמקדים בלמידה **מדור לדור** נציג את הלמידה על **מקטע מס' 1**, אך נדגיש שהלמידה מתחקה אחר אותה המגמה על פני כל המקטעים, כפי שניתן לראות בגרף הנ"ל, שניתן כדוגמא על אוכלוסייה מגודל 50 וקצב מוטציה של 0.01. לכן מספיק להציג את הלמידה על מקטע מס' 1 בלבד וזה מה שנעשה בויזואליזציות והניתוחים הבאים.

4.3 השפעת גודל האוכלוסייה:

4.3.1 השפעת גודל האוכלוסייה על הלמידה הגנטית מדור לדור

נתמקד בלמידה שבוצעה על מקטע יחיד (מקטע 1), כאשר קיבענו את אחוז המוטציות בכל פעם.



אבחנות:

1. כפי שניתן לראות, לכל ערך מוטציה מתקיים שעם הגידול באוכלוסייה גם גדלה יכולתנו להגיע לפתרון כשיר יותר, מהר יותר. כמו כן, ניתן להבחין משלושת הגרפים שערך הכשירות של האינדיבידואל המיטיב נע בטווח קבוע בין 2.5 ל-5, וכי ממיקום מסוים נראה שגודל אוכלוסייה שבין 50 ל-100 מניב תוצאות קרובות.
2. מן השוני בין שלושת הגרפים ניתן לאמוד דווקא את השפעת קצב המוטציה: ברוב המקרים ההתכנסות עבור מוטציות נמוכות נראית "חלקה" יותר. יוצאי הדופן הם הגרפים עבור גודל אוכלוסייה קו (ב-20 פרטים).

מסקנות:

1. ניתן לראות שלגודל האוכלוסייה יש משמעות ממשית על התוצאות שנקבל, כאשר גודל אוכלוסייה קטן (כ-20 פרטים) מניב תוצאות נמוכות משמעותית מאשר התוצאות על אוכלוסייה גדולה יותר (כ-100 או 50

פרטים) אך כי ביניהם אין הבדל משמעותי.

מכיוון שזמן הריצה על 100 אינדיבידואלית כפול מזמן הריצה על 50 אינדיבידואלים, נסיק כי מבין הפרמטרים הנמדדים נעדיף אוכלוסייה המורכבת מ-50 פרטים.


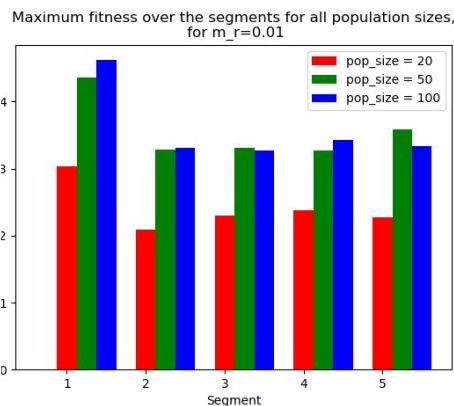
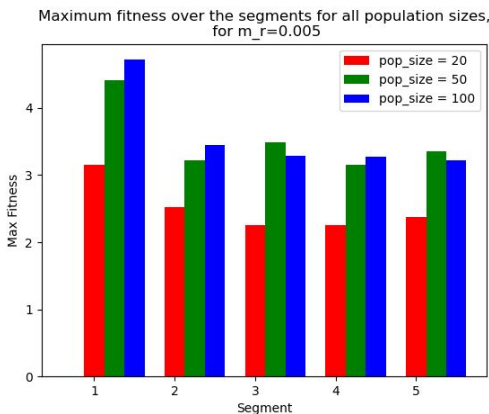
2. ניתן להסיק ש**קצב המוטציה** משפיע על ההתכנסות: עבור קצב מוטציה נמוך, הפתרון מושג בדורות נמוכים יותר ואם הוא מצליח להתכנס, הוא מוביל להתכנסות חלקה, אולם התכנסות זאת לא מבטיחה את איכות הפתרון כפי שהדגשנו בסעיף 3. מנגד, קצב מוטציה גבוה מקשה על האלגוריתם להתכנס, והגרף נראה כ"מזגזג".

תופעות אלו ניתנות לאבחנה בגדלי אוכלוסייה גדולים יותר. מסקנה זו עומדת בשורה אחת עם מסקנות ממחקרי אלגוריתמים מרחבי העולם שגורסים כי גדלי אוכלוסייה קטנים בשילוב עם קצב מוטציה נמוך מביאים להומוגניות גנטית שמנוונת את הפתרון ולא מאפשרת את התעלותו למקסימום גלובלי.

3. מן הקפיצה בגרף השמאלי ניתן להסיק ש**פונקציית ה-fitness** הנבדקת אינה טובה מספיק, היא לא הצליחה לשמר את האינדיבידואל המיטבי: ניתן לראות שבדור 7 האלגוריתם הצליח לייצר אינדיבידואל "חזק" מבחינה גנטית אך לאחר כמה דורות, איבדנו אותו ולא הצלחנו ליצור שוב אינדיבידואל בעל רמת כשירות שכזו.

4.3.2 השפעת גודל האוכלוסייה על הלמידה הגנטית בין מקטעים

נקבע את קצב המוטציה בכל גרף, ונבחן את הלמידה בין הסגמנטים של המשחק כתלות בגודל האוכלוסייה.



אבחנות-

1. באופן כללי לכל ערך מוטציה ובכל סגמנט, היחסים בין ערך הכשירות של האינדיבידואל המיטבי נשמרים בין כל ערכי גדלי האוכלוסייה.
2. בתחילה גודל אוכלוסייה גדול (כ-100 פרטים) משיג פתרון טוב יותר מאשר אוכלוסייה קטנה או בינונית (המונות 20 או 50 פרטים, בהתאמה), ולאחר מכן היחס בין ערך הפיטנס המקסימלי מתאזן בין האוכלוסייה הבינונית לגבוהה.


מסקנות-

1. האבחנות מחזקות את המסקנות שקיבלנו ב-4.1.1 לפיהן אוכלוסייה של 20 אינה מספקת עושר גנטי שנדרש לפתרון מיטב של האלגוריתם. כמו כן, ההבדלים בין איכות הפתרון שמספקות אוכלוסיות של 100 ו-50 בגבולות הפרמטרים שנבחנו שוליים, ואין הצדק לזמן ההרצה הכפול.

4.4. השפעת אחוז המוטציה:

4.4.1. השפעת אחוז המוטציה על הלמידה הגנטית מדור לדור

נתמקד בלמידה שבוצעה על מקטע יחיד (מקטע 1), כאשר קיבענו את גודל האוכלוסייה בכל פעם.



אבחנות-


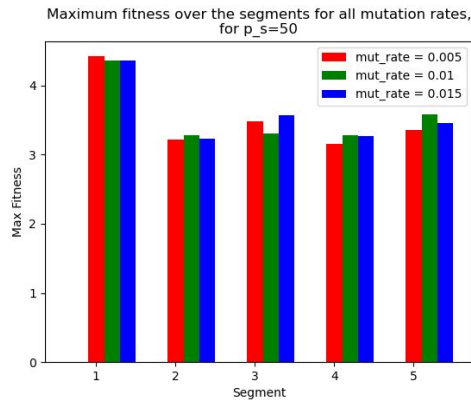
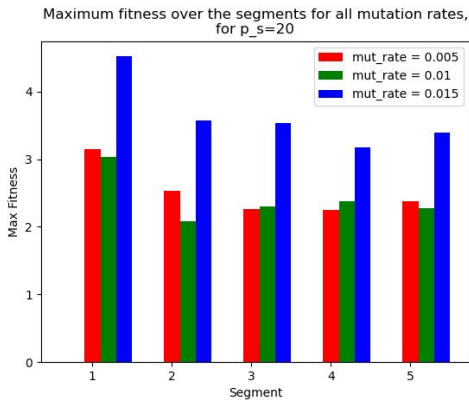
1. לכל גודל אוכלוסייה, **קצב המוטציה** משפיע פחות על גבול ההתכנסות, כל הפתרונות מצליחים להגיע לגבול בקצב שונה.
2. למוטציות שונות יש השפעות שונות על **גדלי אוכלוסייה** שונים אך ההשפעות קטנות ככל שהאוכלוסייה גדלה, ופעולתן נעשית בצורה "חלקה" יותר.
3. לפרמטר המוטציה 0.015 ישנה השפעה מאוד שונה על אוכלוסיה בגודל 50.
4. ניתן לראות שפתרון מתכנס בצורה מהירה יותר עבור קצב מוטציה נמוך יותר.

מסקנות-

1. הגרף שמציג מציג את קצבי המוטציות מעל **גודל אוכלוסייה** של כ-20 אינדיבידואלים מגבה את מסקנותינו מ-4.1.1. אוכלוסייה שכזו רגישה יותר לרעשים ולכן לא ניתן להסיק ממנה ידע קונקרטי על איכות המוטציות השונות.
2. ניתן להסביר את אבחנה 3 בכך שבריצה זו היינו "תקועים" במקסימום לוקלי, אך המוטציה הגבוהה הצליחה לעבור משוכה זו, לא מובטח שקצב מוטציות נמוך יותר היה מצליח להתגבר כך.
3. מאבחנה 2, ניתן להסיק כי בעצם כך שקבענו את פרמטר קצב המוטציה לאוכלוסייה, ולא התנינו אותו בגודל האוכלוסייה, חטאנו לבדיקה והיא אינה איכותית מספיק. בשביל להגיע לבדיקה אפקטיבית יותר, יש לבצע בדיקה מעמיקה יותר עם פרמטרים **דינמיים**. ספציפית כאן יש להגדיל את קצב המוטציה בהתאם לגידול באוכלוסייה. ייתכן שהגענו לאופטימום לוקלי ונשארו בו בשל הניוון שנובע מהחלשת המוטציה של האוכלוסייה.
4. מוטציה גבוהה מדי פוגעת בקשר שבין הפתרון הטוב ביותר לבין הצאצאים שלו, ובכך לא מאפשרת ללמידה הגנטית להתרחש מדור דור. לכן היא עלולה לשבש את איכות הפתרון שקיבלנו לאחר הכלאת הפתרונות הטובים ביותר מהדור הקודם.

4.4.2 השפעת אחוז המוטציה על הלמידה הגנטית בין מקטעים

נקבע את קצב המוטציה בכל גרף, ונבחן את הלמידה בין הסגמנטים של המשחק כתלות בקצב המוטציה.



אבחנות-

1. בכל אוכלוסייה, בין כל סגמנטים היחסים נשמרים באופן כללי.
2. באוכלוסייה מגודל קטן היחסים שונים מאשר היחסים באוכלוסיות הגדולה והבינונית, בהן היחסים כן דומים.

מסקנות-

1. קצב מוטציה בעל השפעה נמוכה יותר ככל שהאוכלוסייה גדלה. מסקנה זו עומדת בקנה אחד עם המסקנה לגבי הפתעה בין דור לדור כפי שראינו ב- 4.1.2.

5. מסקנות

- גידול באוכלוסייה הוא בעל השפעה דומיננטית יותר יחסית לשינוי בקצב המוטציה, כאשר אוכלוסייה מצומצמת מידי לא מניבה מידע בעל משמעות לתהליך הלמידה. עם זאת, הממצאים נותנים לנו הערכה גסה לסף גודל האוכלוסייה שמניב תוצאות שניתן ללמוד מהן, כאשר איכות הגנום של אוכלוסייה בגודל 50 קרובה מאוד לאיכות הגנום של אוכלוסייה בגודל 100, אך מבחינה חישובית כמובן יעיל יותר בהרבה לבחון את המקרים עם אוכלוסייה בגודל 50.
- הפרמטרים שאיתם אמדנו את יכולות האלגוריתם הגנטי נתנו לנו מבט כללי על יכולות האלגוריתם. עם זאת, פתחו עוד אפשרויות לבדיקה יעילה יותר המתחשבת בעוד פרמטרים כמו מס' הדורות בכל מקטע, וכן שימוש בפרמטרים דינמיים אשר מחוץ לגבולות פרוייקט זה.
- אמנם מהממצאים נראה שנשמרת עקביות באיכות הפתרונות הכי טובים, אך כאשר בסוף הריצה בוחנים את הפתרון או הפתרונות שצלחו את המשחק - אפשר לראות שהפתרון הטוב ביותר לסגמנט X לא בא מהפתרון הטוב ביותר לסגמנט X-1, ולכן כנראה בסגמנט X-1 הגענו לפתרון

לוקלי. בפרט פתרון מיטבי לכל המשחק לא בהכרח מושתת על פתרונות מיטביים של הסגמנטים הקודמים לו, וכך בעצם פתרון לוקלי לסגמנט מסויים לא מבטיח שהוא הפתרון עם המקסימום הגלובלי שינצח את המשחק.

6. נספחים

6.1. קשיים בפתרון הבעיה

במהלך העבודה על פתרון הבעיה נתקלנו במספר אתגרים, אשר רובם היו קשורים לאופן מימוש המשחק עצמו. תחילה, מימוש המשחק הינו פרויקט גמר של מספר סטודנטים מגרמניה דבר שהערים מספר קשיים:

- בחלק מן הפונקציות התייעוד היה חסר ובאחרות התייעוד נכתב בגרמנית.
- ההתמודדות עם שגיאות בקוד לעיתים הסתכמה בהדפסת "fix ur s%*t".
- המשחק כלל באגים שגרמו להצגה שגויה של האובייקטים במשחק כגון המגדלים, הקליעים האויבים ואף הרקע.
- למשחק היו תפריטים ומאפיינים שלא היו נחוצים לנו ואף הפריעו במהלך מימוש הלמידה.
- חוסר בטיפול בהערות ובשגיאות בקוד. דוגמא לכך היא שגיאת "canvas as not been attached" בה לבטח ייתקל מי שינסה להריץ את תהליך הלמידה. היא איננה מפילה את תהליך הלמידה ולכן בליט ברירה בחרנו להתעלם ממנה.

עם זאת, הקשיים הנ"ל היו קלים לפתרון (או ניתנים להתעלמות) ביחס לקשיים שהיו כרוכים בשימוש המשחק בספריות פייתון: Pygame, Cocos2d.

ספריות אלו הינן ספריות מבוססות ליצירת משחקים המאפשרות למשתמש להגדיר בקלות תפריטים, רקעים, סצנות, sprites (אויבים\מגדלים), יריות וחוקיות אשר חלה על מרכיבים אלו.

יחד עם הנוחות בשימוש בספריות אלו, ישנם מספר חסרונות בולטים:

- המימוש של cocos2d לוקח על עצמו את הטיפול בלוגיקה (תנועת השחקנים, חיי האויבים וכו') ובגרפיקה של המשחק, כך שלא יכלנו להריץ את המשחקים ברמה הלוגית בלבד, ללא גרפיקה, בכדי לקצר את הזמן הנדרש בכדי להריץ כל סיבוב.
- לא הצלחנו למצוא דרך להריץ מספר משחקים בו זמנית, כנראה בגלל מימוש מחלקות מסויימות ב-cocos2d וב-pygame כסינגלטונים.

המגבלות הנ"ל האטו מאוד את קצב הלמידה ולכן נאלצנו לערוך את קוד המשחק המקורי בכדי לקצר את זמן הריצה באמצעות השינויים הבאים:

- ביטול האנימציות של תזוזת האויבים ושל פיצוצים.
- ביטול תפריטים, highscores, זמן ההמתנה בין הגלים וכותרות המעידות על הופעת גלים חדשים.
- החלת מכפיל האצה על קצב יריית המגדלים, תנועת האויבים וקצב הופעתם.
- החלת מכפיל המקטין את משך השפעת יריות "רעל" והאטה על האויבים.
- ביטול vsync - מאפיין המגביל את קצב הפריימים במשחק לקצב רענון המסך.

כמו כן הקטנת מימד הבעיה, צמצום מרחב החיפוש, דרשה מאיתנו לערוך את הקוד כדי להגדיר מחדש מהי משבצת לוח שעליה ניתן לבצע פעולות ומהי הקוארדינטה החדשה לסיום הדרך. בנוסף, בשל ההקטנה צמצמנו טווחי השפעה וירי של מגדלים שונים כדי לשמור על פרופורציה נכונה אל מול הלוח החדש.

